

# Logistic regression, classification

- Правдоподобие
- Метод максимального правдоподобия
- MSE
- линейная регрессия
- $H_0$  и  $H_1$  (альтернативная)
- Sensitivity
- Specificity

# Задача классификации


По признакам -  $X$  мы должны определить  
класс-  $C$

Теперь у нас есть четкие ограничения для  
предсказания моделей. Они должны быть  $N$   
(0 тоже входит и иногда при бинарной  
классификации -1)

Как по-другому поставить задачу (более  
формально)?

Почему не решать её как регрессионную задачу?





# Самый простой вариант линейного классификатора

!Сейчас будем говорить только о бинарной классификации!

$$c(x) = \begin{cases} 1, & \text{if } f(x) \geq 0 \\ -1, & \text{if } f(x) < 0 \end{cases}$$

Margin(отступ)

$$M_i = y_i \cdot f(x_i)$$

Главное свойство: если margin положителен, то классификация успешна

$$M_i > 0 \Leftrightarrow y_i = c(x_i)$$

$$M_i \leq 0 \Leftrightarrow y_i \neq c(x_i)$$


Loss функция для классификации (если нас не отпускает регрессия)

$$\begin{aligned} L_{\text{MSE}} &= (y_i - x_i^T w)^2 = \frac{(y_i^2 - y_i \cdot x_i^T w)^2}{y_i^2} = \\ &= (1 - y_i \cdot x_i^T w)^2 = (1 - M_i)^2 \end{aligned}$$

Почему это плохо?

# Логистическая регрессия

Логистическая регрессия — это тип регрессии, в которой мы оцениваем наличие связи между бинарной зависимой переменной и одной или несколькими независимыми переменными.






# Сигмоида

Какая особенность у этой функции?

Почему именно она используется для классификации?

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$



## Метод максимального правдоподобия

$$\log L(w|X, Y) = \log P(X, Y|w) = \log \prod_{i=1} P(x_i, y_i|w)$$

Какой шаг пропущен?


$$\log L(w|X, Y) = \sum_{i=1}^n \log \sigma_w(M_i) = - \sum_{i=1}^n \log(1 + \exp(-M_i)) \rightarrow \max_w$$

# Log loss

$$L(w, X, y) = - \sum_i (y_i \log(\sigma(\langle w, x_i \rangle)) + (1 - y_i) \log(\sigma(-\langle w, x_i \rangle)))$$

Что-то напоминает?

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$



# Итак, почему же это всё-таки регрессия?

Модель на выходе нам дает следующее значение:

$$p = \sigma(\langle w, x_i \rangle)$$

Как тогда определить класс в случае бинарной классификации?

# Многоклассовая классификация

В чем отличия от бинарной?

Как бороться с новыми проблемами?

# One vs Rest


Пытаемся отличить наш  
класс от остальных

то есть  $> 0.5$  - наш класс


$< 0.5$  - другой

Какие минусы?


Что будем делать с  
серединой?




Class 0 vs others




Class 1 vs others



Class 2 vs others




Predicted classes



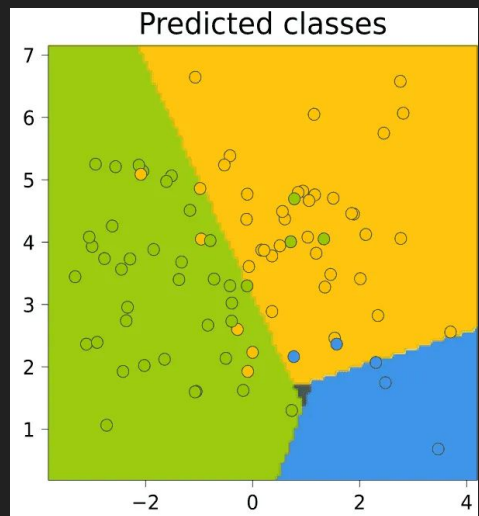
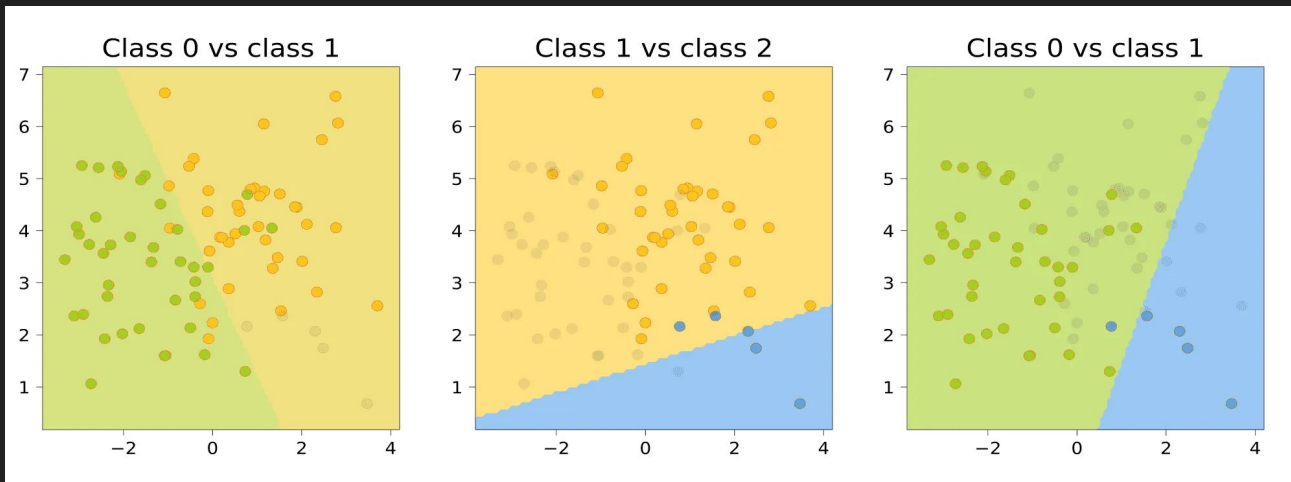
# One vs One

Обучаем классификатор, чтобы он понимал где класс 0 (-1), а где 1(+1)

Делаем так для всех классов в выборке







# Сравним эти 2 стратегии

## One vs rest:

- Кол-во классификаторов == кол-ву классов
- Учимся на всей выборке

## One vs one:

- Кол-во классификаторов ==  $k(k-1)/2$
- Учимся на подвыборках

# Метрики

1. Accuracy( balanced accuracy)
2. Precision
3. Recall
4. F-score
5. ROC-curve (ROC-AUC)
6. PR (PR-AUC)
7. Confusion matrix

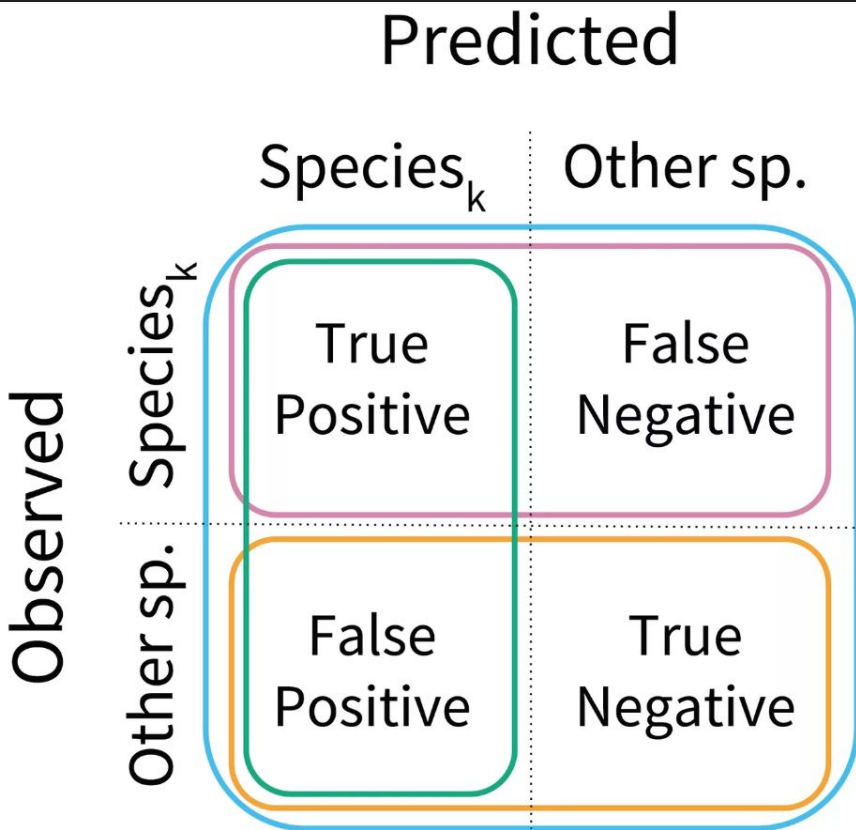
# Accuracy

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n [y_i^t = y_i^p]$$

$$\text{Balanced accuracy} = \frac{1}{C} \sum_{k=1}^C \frac{\sum_i [y_i^t = k \text{ and } y_i^t = y_i^p]}{\sum_i [y_i = k]}$$

		Верная гипотеза	
		$H_0$	$H_1$
Результат применения критерия	$H_0$	$H_0$ верно принята	$H_0$ неверно принята (Ошибка <i>второго</i> рода)
	$H_1$	$H_0$ неверно отвергнута (Ошибка <i>первого</i> рода)	$H_0$ верно отвергнута

# Precision и Recall




$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$



$$\text{Specificity} = \frac{TN}{TN + FP}$$



$$\text{Precision} = \frac{TP}{TP + FP}$$




$$\text{Recall} = \frac{TP}{TP + FN}$$

# F-score


$$F_1 = \frac{2}{\text{precision}^{-1} + \text{recall}^{-1}} = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

$$F_\beta = (1 + \beta^2) \frac{\text{precision} \cdot \text{recall}}{\beta^2 \text{precision} + \text{recall}}$$



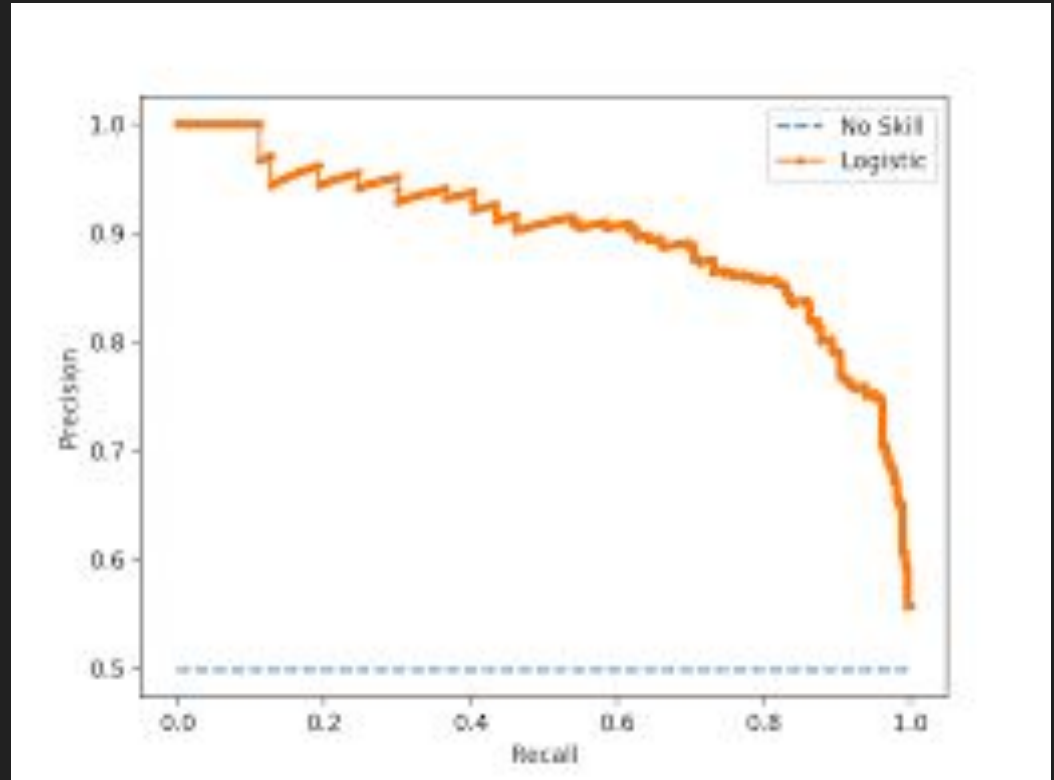
# ROC - AUC

$$\text{FPR} = \frac{FP}{FP + TN}$$
$$\text{TPR} = \frac{TP}{TP + FN} (= \text{Recall})$$





# PR (PR-AUC)



# Confusion Matrix

